

问题三可解释性多模态情感预测模型

1 问题分析

问题三要求在三模态信息完整的条件下，同时完成情感极性分类、情感强度回归和预测依据解释。与只输出一个类别的情感分类任务相比，本问题至少包含三个相互关联的目标：

1. 判断样本属于 Negative、Neutral 或 Positive；
2. 预测区间为 $[-3, 3]$ 的连续情感强度；
3. 量化文本、语音和视觉模态对当前预测的作用，并将重要依据回溯至文本相对窗口、音频时间段和视觉关键帧。

三种模态的采样频率、特征维度和有效长度不同，且局部内容可能缺失或只是填充位置。若直接拼接原始特征，容易使高维文本特征支配融合结果，并将填充位置误当成有效情感线索；若只读取注意力权重或门控权重，也不能证明某一输入真正改变了模型输出。因此，本文采用“掩码感知时序编码—文本引导跨模态交互—样本级动态融合—分类回归联合预测—反事实遮挡解释”的建模思路。预测模型训练完成后固定参数，再通过模态级和局部窗口级干预测量输出变化，从而形成可复核的模型敏感性证据。

本文的解释对象是模型决策过程，而不是人工标注的情感成因。因而全文使用“模态贡献”“局部证据”“模型敏感性”等术语，不将其表述为心理学意义上的因果原因。

2 模型假设

假设 1：每个样本的文本、语音和视觉特征可表示为有序时序序列；序列位置之间的相对顺序包含情感表达信息。

假设 2：特征文件提供的有效位置掩码能够区分真实观测、填充位置和无效位置。所有自注意力、跨模态注意力和池化操作均遵守该掩码。

假设 3：训练集统计量可以代表预处理所需的尺度信息。标准化均值和标准差只由训练集拟合，验证集、测试集和无标签专项样本复用该统计量。

假设 4：情感极性与情感强度共享一部分多模态表示，但二者的预测边界不同，因此使用共享编码器和相互独立的分类头、回归头。

假设 5：将一个模态或局部窗口替换为训练集基线后，模型输出的变化可以作为该输入区域的预测敏感性度量，但该度量不等同于真实因果效应。

假设 6: 对齐特征中的相同序号表示相对对齐窗口，而不必然表示逐词、逐帧的真实时间戳。文本证据因此只定位到相对窗口；视频证据只有在素材可解码且映射有效时才生成关键帧。

3 符号说明

符号	含义
i	样本编号, $i = 1, \dots, N$
$m \in \{T, A, V\}$	文本、语音和视觉模态
$X_i^{(m)}$	样本 i 的模态 m 特征序列
L_m	模态 m 的序列长度; 对齐版本中统一为 50
d_m	模态 m 的输入特征维度
$M_i^{(m)}$	模态 m 的有效位置掩码
d	统一隐空间维数, 当前取 64
$H_i^{(m)}$	模态 m 的上下文编码序列
$g_i^{(m)}$	模态 m 的掩码平均摘要向量
$\alpha_i^{(m)}$	样本级动态融合门控值
p_i	三分类预测概率向量
$\hat{y}_i$	情感强度预测值
$c_{i,m}$	模态 m 的反事实贡献归一化值
$r_{i,m,k}^{\text{local}}$	模态 m 第 k 个局部窗口的敏感性

4 数据与任务定义

4.1 输入组织

本文选择对齐特征版本作为统一输入。每个样本包含三组序列:

$$X_i^{(m)} = (x_{i,1}^{(m)}, x_{i,2}^{(m)}, \dots, x_{i,L_m}^{(m)}), \quad m \in \{T, A, V\}. \quad (1)$$

对应的有效位置掩码记为

$$M_i^{(m)} = (m_{i,1}^{(m)}, m_{i,2}^{(m)}, \dots, m_{i,L_m}^{(m)}), \quad m_{i,t}^{(m)} \in \{0, 1\}. \quad (2)$$

当 $m_{i,t}^{(m)} = 1$ 时该位置参与编码，当 $m_{i,t}^{(m)} = 0$ 时该位置不参与注意力和池化。当前输入维度为：文本 768、语音 74、视觉 35；对齐序列长度为 50。分类标签映射为0: Negative, 1: Neutral, 2: Positive；情感强度标签在 $[-3, 3]$ 范围内。

4.2 数据边界

附件二的 train、valid、test 划分保持题给边界，数量分别为 3395、728 和 727。训练集用于拟合模型参数和标准化参数；验证集用于早停、模型配置及解释窗口参数选择；测试集只在模型和解释规则固定后报告一次性能。附件四共有 20 个无标签样本，仅用于最终推理和解释展示，不参与训练、调参、早停、阈值选择和真实性能统计。

本次运行的输入特征版本为 aligned_50.pkl，其 SHA-256 为 66e867aa74bc70a844e806e5571e371c9abb4a35f9e2887ce9b4d97ff2cb8fcd，随机种子为 20260924。本文不使用外部情感数据集，也不将公开论文或开源项目的指标写成本实验结果。

5 多模态预测模型

5.1 训练集标准化与模态投影

由于三种模态的量纲和维度不同，先对每个模态的每个特征维度计算训练集均值和标准差。设训练集统计量为 μ_m 与 σ_m ，则

$$\tilde{x}_{i,t}^{(m)} = \frac{x_{i,t}^{(m)} - \mu_m}{\max(\sigma_m, \epsilon)}. \quad (3)$$

其中 ϵ 是防止除零的数值稳定项。式 (3) 的统计量只由训练集有效位置计算，并保存供其他划分复用。之后通过模态专属线性映射将异构特征变换至统一隐空间：

$$e_{i,t}^{(m)} = \text{LN} \left(W_m \tilde{x}_{i,t}^{(m)} + b_m \right), \quad e_{i,t}^{(m)} \in \mathbb{R}^d. \quad (4)$$

其中 $d = 64$ ， W_m 和 b_m 为可学习参数，LN 表示层归一化。该步骤避免高维文本向量因尺度或维数差异直接主导跨模态计算。

5.2 掩码感知的模态内时序编码

对投影结果加入位置表示 p_t ：

$$\bar{e}_{i,t}^{(m)} = e_{i,t}^{(m)} + p_t. \quad (5)$$

每个模态使用独立的 Transformer 编码器提取时序上下文：

$$H_i^{(m)} = \text{Encoder}_m \left(\bar{E}_i^{(m)}, M_i^{(m)} \right). \quad (6)$$

在注意力计算中，键位置为无效位置时不参与 softmax：

$$S_{uv}^{(m)} = \begin{cases} q_u k_v^\top / \sqrt{d}, & m_{i,v}^{(m)} = 1, \\ -\infty, & m_{i,v}^{(m)} = 0. \end{cases} \quad (7)$$

编码后采用掩码平均池化获得模态摘要：

$$g_i^{(m)} = \frac{\sum_{t=1}^{L_m} m_{i,t}^{(m)} H_{i,t}^{(m)}}{\max \left(1, \sum_{t=1}^{L_m} m_{i,t}^{(m)} \right)}. \quad (8)$$

当某模态没有有效位置时，分子为零且摘要置为安全零向量，避免全无效样本发生除零或产生虚假信息。

5.3 文本引导的跨模态交互

文本通常包含较直接的语义内容，语音和视觉则提供语气、表情及动作等补充信息。为控制模型规模，本文以文本序列作为查询，分别从音频和视觉序列提取上下文：

$$R_i^{T \leftarrow A} = \text{MHA} \left(H_i^{(T)}, H_i^{(A)}, H_i^{(A)}; M_i^{(A)} \right), \quad (9)$$

$$R_i^{T \leftarrow V} = \text{MHA} \left(H_i^{(T)}, H_i^{(V)}, H_i^{(V)}; M_i^{(V)} \right). \quad (10)$$

其中键和值均受到相应模态掩码约束。跨模态响应按照文本有效位置进行池化，并加到文本摘要上；随后形成三模态摘要矩阵：

$$\tilde{g}_i^{(T)} = g_i^{(T)} + \text{Pool} \left(R_i^{T \leftarrow A} \right) + \text{Pool} \left(R_i^{T \leftarrow V} \right), \quad G_i = \left[\tilde{g}_i^{(T)}; g_i^{(A)}; g_i^{(V)} \right]^\top. \quad (11)$$

式 (11) 用于增强预测表示，而不是直接作为解释权重。注意力较大只说明表征交互强，不能单独证明其对最终输出具有决定性影响。

5.4 样本级动态融合

不同样本中各模态的可靠性不同。对每个模态计算门控打分：

$$a_i^{(m)} = w^\top G_{i,m} + b, \quad (12)$$

并在有效模态集合上归一化：

$$\alpha_i^{(m)} = \frac{q_i^{(m)} \exp(a_i^{(m)})}{\sum_{r \in \{T, A, V\}} q_i^{(r)} \exp(a_i^{(r)}) + \epsilon}, \quad (13)$$

其中 $q_i^{(m)} = 1$ 表示该模态存在有效观测， $q_i^{(m)} = 0$ 表示整体缺失。融合表示为

$$z_i = \text{MLP} \left(\sum_{m \in \{T, A, V\}} \alpha_i^{(m)} G_{i,m} \right). \quad (14)$$

门控值用于说明模型内部如何组合模态表示，但不直接定义为模态贡献。最终贡献由第 6 节的反事实干预重新计算。

5.5 分类回归双任务输出

分类头输出三类 logits 和概率：

$$o_i^{\text{cls}} = W_{\text{cls}} z_i + b_{\text{cls}}, \quad p_i = \text{softmax}(o_i^{\text{cls}}). \quad (15)$$

分类损失为交叉熵：

$$\mathcal{L}_{\text{cls}} = -\frac{1}{B} \sum_{i=1}^B \sum_{c=0}^2 y_{i,c} \log p_{i,c}. \quad (16)$$

当前运行未启用类别加权，类别权重参数记录为关闭。回归头通过双曲正切函数约束预测范围：

$$\hat{y}_i^{\text{reg}} = 3 \tanh(w_{\text{reg}}^\top z_i + b_{\text{reg}}). \quad (17)$$

回归损失采用 Smooth L1 损失：

$$\mathcal{L}_{\text{reg}} = \frac{1}{B} \sum_{i=1}^B \text{SmoothL1}(\hat{y}_i^{\text{reg}} - y_i^{\text{reg}}). \quad (18)$$

联合训练目标为

$$\mathcal{L} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{reg}} \mathcal{L}_{\text{reg}}, \quad \lambda_{\text{cls}} = \lambda_{\text{reg}} = 1. \quad (19)$$

共享表示使分类边界和连续强度估计相互提供信息，而两个任务头保持输出语义独立。

6 反事实可解释性模型

6.1 模态级贡献

设完整输入的输出为 $(p_i, \hat{y}_i)$ 。对模态 m 进行干预时，将该模态的特征替换为训练集均值基线，并在标准化训练特征空间中保持对应的有效位置语义，得到输出 $(p_i^{-m}, \hat{y}_i^{-m})$ 。分类输出变化用 KL 散度度量，回归输出变化用绝对差度量：

$$\Delta_{i,m}^{\text{cls}} = D_{\text{KL}}(p_i \| p_i^{-m}), \quad \Delta_{i,m}^{\text{reg}} = |\hat{y}_i - \hat{y}_i^{-m}|. \quad (20)$$

在验证集预先确定两类变化的尺度后，定义综合敏感性：

$$r_{i,m} = \rho \tilde{\Delta}_{i,m}^{\text{cls}} + (1 - \rho) \tilde{\Delta}_{i,m}^{\text{reg}}. \quad (21)$$

将非负敏感性归一化，得到模态贡献：

$$c_{i,m} = \frac{\max(r_{i,m}, 0)}{\sum_{r \in \{T, A, V\}} \max(r_{i,r}, 0) + \epsilon}. \quad (22)$$

三种模态的 $c_{i,m}$ 之和约为 1，最大者记为当前样本的主要参考模态。需要强调，式 (22) 描述的是“移除该模态后模型输出改变了多少”，不是人类情感形成机制的因果证明。

6.2 局部窗口证据

对模态 m 的有效序列按照窗口长度 $w = 7$ 、步长 $s = 7$ 划分局部窗口 $J_{i,m,k}$ 。对窗口内特征和掩码同步进行基线替换，得到局部干预输出 $(p_i^{-m,k}, \hat{y}_i^{-m,k})$ 。局部敏感性定义为

$$r_{i,m,k}^{\text{local}} = \rho D_{\text{KL}}(p_i \| p_i^{-m,k}) + (1 - \rho) |\hat{y}_i - \hat{y}_i^{-m,k}|. \quad (23)$$

对每个样本按 $r_{i,m,k}^{\text{local}}$ 降序保留前三个窗口，并输出模态、窗口起止位置、相对时间区间、敏感性值及映射状态。文本窗口表示对齐特征上的相对位置，不等价于逐词真实时间戳；语音窗口映射至相对音频区间；视觉窗口再根据视频帧率映射至关键帧索引。

6.3 解释忠实性选择

解释参数不根据附件四结果选择。验证集对候选窗口进行比较后，最终采用训练集均值基线、窗口长度 7、步长 7、每个样本保留 3 个证据窗口。验证集 728 个样本的高重要性窗口平均影响为 0.0748529，低重要性窗口平均影响为 0.0032877，二者差值为 0.0715652，比例约为 22.77。该结果支持“排序靠前窗口比低重要性窗口具有更强模型敏感性”的诊断，但不代表证据已获得人工真实性标注。

7 算法流程与约束

7.1 预测与解释流程

输入三模态序列和有效掩码

1. 读取固定特征版本，核对样本主键和数据划分
2. 使用训练集统计量标准化三种模态
3. 模态投影、位置编码和掩码感知 Transformer 编码
4. 文本分别查询语音和视觉，获得跨模态表示
5. 计算样本级门控并融合三种模态
6. 输出情感类别概率和情感强度
7. 对完整模态和局部窗口执行基线替换
8. 计算输出变化，归一化模态贡献并排序局部证据
9. 将证据映射至相对时间区间和关键帧，保存数值表与审计信息

7.2 约束条件

模型训练与解释过程满足以下约束：

1. 标准化统计量只能由训练集拟合；
2. train、valid、test 主键保持互不交叉；
3. 掩码必须同时作用于自注意力、跨模态注意力和池化；

4. 测试集不能用于参数选择，附件四不能用于训练、调参、早停或真实性能统计；
5. 所有输出必须保留样本主键、数据划分、特征版本、随机种子和运行配置；
6. 解释结果必须保留证据索引、相对时间信息、映射状态和异常记录；
7. 模态移除诊断属于固定模型的后验诊断，不得写成重新训练的单模态基线。

8 实验设置与评价指标

8.1 训练设置

项目	设置
特征版本	对齐三模态特征，长度 50
输入维度	文本 768，语音 74，视觉 35
隐空间维数	64
Transformer 层数	1
注意力头数	4
Dropout	0.1
Batch size	64
Epoch 数	50
学习率	2×10^{-5}
权重衰减	1×10^{-4}
分类/回归损失权重	1 / 1
随机种子	20260924
解释基线	训练集均值，标准化训练特征空间
解释窗口	长度 7，步长 7，Top-3

当前运行使用题给文本嵌入和声学、视觉特征，未加载外部预训练模型。模型选择以验证集为依据，测试集只用于最终有标签评价。

8.2 评价指标

分类性能报告 Accuracy 和 Macro-F1:

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}(\hat{c}_i = c_i), \quad (24)$$

$$\text{Macro-F1} = \frac{1}{3} \sum_{c=0}^2 F1_c. \quad (25)$$

回归性能报告平均绝对误差和 Pearson 相关系数：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|, \quad (26)$$

$$\text{Pearson}(\hat{y}, y) = \frac{\sum_i (\hat{y}_i - \bar{\hat{y}})(y_i - \bar{y})}{\sqrt{\sum_i (\hat{y}_i - \bar{\hat{y}})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}. \quad (27)$$

9 实验结果与分析

9.1 总体性能

表 1 给出固定配置下的 valid 和 test 结果。所有指标均来自有标签划分；附件四没有真实标签，因此不列入表 1。

表 1 三模态双任务模型性能

划分	Accuracy	Macro-F1	MAE	Pearson
valid (728)	0.607143	0.547565	0.652097	0.580993
test (727)	0.672627	0.595023	0.679413	0.625911

从表 1 可见，测试集的分类准确率为 0.672627，Macro-F1 为 0.595023；连续强度预测的 MAE 为 0.679413，Pearson 相关系数为 0.625911。valid 与 test 的指标差异应理解为有限样本划分下的性能波动，当前只有一个随机种子，不能据此声称模型具有统计显著的泛化优势。

9.2 分类类别表现

表 2 验证集分类报告

类别	Precision	Recall	F1	Support
Negative	0.6465	0.6214	0.6337	206
Neutral	0.4433	0.2337	0.3060	184
Positive	0.6259	0.8018	0.7030	338

验证集上 Positive 类召回率为 0.8018，识别相对充分；Neutral 类召回率为 0.2337，明显低于另外两类，说明中性样本更容易被模型吸收到相邻极性类别。该现象可能与类别边界模糊、标签离散化损失信息以及样本分布有关，但当前实验没有进行多随机种子和重训练基线检验，不能进一步归因于某一种机制。

9.3 后验模态移除诊断

表 3 是在同一个已训练模型上分别移除一个模态后的后验诊断。它不是重新训练的单模态模型，因此只用于分析当前融合模型对不同模态的依赖。

表 3 固定模型的模态移除诊断

划分	移除模态	Accuracy	Macro-F1	MAE	Pearson
valid	none	0.607143	0.547565	0.652097	0.580993
valid	text	0.287088	0.263764	0.869413	-0.020699
valid	audio	0.604396	0.571687	0.716655	0.579688
valid	vision	0.629121	0.576199	0.694256	0.573931
test	none	0.672627	0.595023	0.679413	0.625911
test	text	0.288858	0.266980	0.989222	-0.064822
test	audio	0.678129	0.625366	0.733368	0.638242
test	vision	0.672627	0.592638	0.725985	0.613138

移除文本后，valid Accuracy 从 0.607143 降至 0.287088，Pearson 从 0.580993 降至 -0.020699；test Accuracy 从 0.672627 降至 0.288858，Pearson 降至 -0.064822。这说明当前模型的预测表示对文本模态高度敏感。音频和视觉移除后的分类指标变化较小，但回归误差上升，说明它们在当前模型中可能更多补充情感强度信息。由于表 3 没有重新训练被移除模态后的模型，结论应限定为“当前模型的后验输入依赖”。

9.4 局部证据与映射质量

验证集解释参数选择中，高重要性窗口的平均影响为 0.0748529，低重要性窗口为 0.0032877，二者差值为 0.0715652。该差异说明遮挡排序能够在模型层面区分敏感窗口。相关热力图用于展示 valid、test 和附件四的局部影响分布；门控权重与贡献关系图用于说明内部融合值和反事实贡献并非同一个量。

证据映射表记录每条证据的样本编号、模态、窗口位置、相对时间、影响分数、关键帧索引和映射状态。视频审计显示 20 个附件四视频均能完成解码，但其中 16 个视频的容器声明帧数与实际解码帧数不一致。因此，关键帧索引以实际解码结果为准，并保留该异常记录；不能根据容器声明帧数反推不存在的画面。

9.5 代表性样本的解释方式

为了展示模态作用差异，可在正文选取文本主导、音频主导、视觉主导、分类错误和回归误差较大的样本进行案例分析。案例表至少报告真实类别、预测类别、真实与预测强度、三模态贡献和主要模态。当前结果中，文本主导样本 jICmfLeFymA\$_\$16 的三模态贡献约为 0.9764、0.0053、0.0184，且分类正确；音频主导样本 PboaYD5h1G8\$_\$8 的音频贡献约为 0.7353，但真实类别为 Negative 而预测为 Positive；视觉主导样本 wosolsrH3sM\$_\$6 的视觉贡献约为 0.7490，分类同样出现偏差。这些案例说明“主要模态”是模型当前的依赖对象，并不保证该模态能够给出正确判断。

10 附件四推理输出与可解释结果

附件四无真实标签，本文仅报告预测类别、预测强度、主要模态、模态贡献、Top-3 局部证据、视频映射状态和关键帧。20 个样本均生成预测记录和证据卡；预测强度由式 (17) 约束在 $[-3, 3]$ 。其中样本 01 预测为 Positive，预测强度约为 0.6411，主要模态为文本；样本 09 预测为 Negative，预测强度约为 -1.9809，主要模态为文本；样本 18 预测为 Positive，预测强度约为 -1.0973，主要模态为视觉。最后一个例子说明分类极性和连续强度是两个不同输出，不能仅依据预测类别推断强度符号。

对于每个附件四样本，输出证据卡和关键帧元数据，记录文件名、样本编号、模态、相对窗口、帧索引、时间区间、影响分数和映射状态。文本证据没有逐词精确时间戳；视频容器帧数异常样本按照实际解码帧数进行边界检查。由于缺少真实标签，附件四结果不能计算 Accuracy、F1、MAE 或 Pearson，也不能用于选择更有利的样本、窗口或基线。

11 图表编排说明

正文建议按以下顺序编排已经生成的图表：

1. **图 1 技术路线图**：展示输入、标准化、掩码编码、跨模态注意力、动态融合、双任务预测和反事实解释的先后关系，说明预测和解释共享同一固定模型。
2. **图 2 模型结构图**：展示三条模态编码支路、文本到语音/视觉的查询关系、门控融合以及分类回归双头，避免将门控箭头误标成因果关系。
3. **图 3 数据边界图**：展示附件二 train/valid/test 的训练、选择和评价边界，以及附件四仅推理的边界。
4. **图 4 训练曲线**：展示 epoch 与训练/验证损失的变化，仅用于说明优化过程，不替代泛化性能评价。
5. **图 5–7 局部重要性热力图**：分别展示 valid、test 和附件四的窗口敏感性分布，并在图注中注明附件四无标签。
6. **图 8 门控与反事实贡献关系图**：说明内部门控与输出敏感性是两个不同量，不能直接互换。
7. **图 9 混淆矩阵**：分别展示 valid 与 test 的类别混淆结构，配合表 2 讨论 Neutral 类召回不足。
8. **图 10 回归诊断图**：展示真实强度和预测强度的散点及误差分布，配合 MAE 和 Pearson 解释回归结果。
9. **图 11 映射质量和视频审计图**：展示证据映射状态、实际解码帧数与容器声明帧数差异，避免将异常素材当作模型错误。

每张图均应在正文中说明统计对象、数据划分、横纵坐标含义和解释边界。定性案例应同时引用数值证据表、证据映射记录和关键帧元数据，不能只展示图片而缺少可回溯索引。

12 模型局限与可复现说明

当前实验仍有以下限制：第一，尚未完成不同结构的重新训练基线，因此模态移除结果不能替代完整消融实验；第二，当前结果来自单一随机种子，尚无多随机种子均值、标准差和置信区间；第三，文本定位是对齐相对窗口而非逐词时间戳；第四，部分视频存在容器帧数和实际解码帧数不一致；第五，反事实影响值、门控值和注意力权重都不能被解释为真实情感原因。

为保证复现，应同时保存特征版本及校验和、数据划分数、随机种子、模型配置、训练日志、最佳模型、训练集标准化参数、预测表、解释表、关键帧 JSON 元数据、视频解码审计和输出校验摘要。任何改变特征版本、训练轮数、损失权重、解释基线或窗口

参数的实验，都应视为新的独立运行，并重新生成完整的预测和解释材料。