

问题三：可解释性多模态情感预测

1 问题分析与建模目标

问题三要求在三模态信息完整的条件下，同时输出情感极性、情感强度以及能够回溯到原始素材的解释证据。模型不仅要回答“样本属于哪一类、强度是多少”，还要回答“文本、语音和视觉分别起到了多大作用，以及哪一段信息改变了当前判断”。因此，本问题被建模为一个带有后验反事实解释的多任务学习问题。

三模态具有不同的特征维度、时间组织方式和有效长度。直接拼接可能造成高维文本特征主导训练，也可能使填充位置参与注意力计算。另一方面，模型内部的注意力和门控值只反映表征交互或融合状态，不能单独证明某个片段真正影响了最终输出。本文据此采用如下路线：先在训练集边界内完成标准化，再进行掩码感知的模态内时序编码；以文本为查询完成音频和视觉交互；通过动态门控获得样本级融合表示；利用分类头和回归头联合预测；最后固定模型参数，以训练集均值为反事实基线，执行模态级和局部窗口级遮挡，生成贡献度、证据映射、关键帧和解释卡。

图 1 展示了从特征输入到证据输出的完整流程。图中预测主干和解释分支共享同一个最佳模型，解释阶段不再更新模型参数，也不使用附件四选择超参数。

2 模型假设与符号定义

2.1 模型假设

- (1) 每个样本的文本、语音和视觉信息均可表示为保序时序序列，序列位置的相对关系包含情感表达信息。
- (2) 特征文件提供的有效掩码能够区分有效观测、填充位置和无效位置；掩码同时作用于自注意力、跨模态注意力和池化。
- (3) 预处理统计量只由训练集估计，验证集、测试集和附件四复用训练集统计量。
- (4) 情感极性和强度共享多模态语义表示，但使用独立输出头，因为分类边界和连续强度并不等价。
- (5) 遮挡模态或局部窗口后产生的预测变化表示模型敏感性，不等同于真实情感成因或人类心理因果关系。
- (6) 对齐特征的相同序号表示相对对齐窗口，不保证逐词、逐帧的真实时间戳；文本证据因而只报告对齐相对窗口。

2.2 符号定义

符号	含义
i	样本编号, $i = 1, \dots, N$
$m \in \{T, A, V\}$	文本、音频、视觉模态
$X_i^{(m)}$	模态 m 的输入序列
$M_i^{(m)}$	模态 m 的有效位置掩码
d_m	模态 m 的输入维度
d	统一隐空间维数, 取 64
$H_i^{(m)}$	模态内 Transformer 编码结果
$g_i^{(m)}$	模态摘要向量
$G_{i,m}$	交互增强后的模态摘要
$\alpha_i^{(m)}$	动态门控值
p_i	三分类概率向量
$\hat{y}_i$	情感强度预测值
$c_{i,m}$	反事实模态贡献
$r_{i,m,k}^{local}$	第 k 个局部窗口的敏感性

3 数据边界与输入输出

3.1 数据组织

本文固定使用对齐特征版本 `aligned_50.pkl`。每个模态序列表示为

$$X_i^{(m)} = (x_{i,1}^{(m)}, \dots, x_{i,L_m}^{(m)}), \quad m \in \{T, A, V\}, \quad (1)$$

有效掩码为

$$M_i^{(m)} = (m_{i,1}^{(m)}, \dots, m_{i,L_m}^{(m)}), \quad m_{i,t}^{(m)} \in \{0, 1\}. \quad (2)$$

当前文本、语音和视觉特征维度分别为 768、74 和 35, 对齐序列长度为 50。分类标签映射为 0: Negative、1: Neutral、2: Positive; 回归标签范围为 $[-3, 3]$ 。本次运行的特征 SHA-256 为 66e867aa74bc70a844e806e5571e371c9abb4a35f9e2887ce9b4d97ff2cb8fcd。

3.2 数据边界

附件二 train、valid、test 样本数分别为 3395、728 和 727。训练集只用于拟合模型与标准化统计量；验证集用于选择模型和解释参数；测试集仅用于最终有标签评价。附件四有 20 个无标签样本，只进行固定模型推理和解释生成，不参与训练、调参、早停、阈值选择或性能统计。

图 2 给出数据边界。该边界是本文所有实验结果可解释性的前提：附件四预测不能写成 Accuracy、F1、MAE 或 Pearson。

3.3 输入输出定义

模型输入为三模态特征、三模态有效掩码、数据划分和样本主键。模型输出包括分类概率、预测类别、情感强度、门控值；解释模块进一步输出模态敏感性、归一化贡献、主要模态、局部窗口起止位置、相对时间、帧索引和映射状态。predictions_valid.csv、predictions_test.csv 和 predictions_attachment4.csv 保存预测结果；local_importance_*.csv 保存局部遮挡影响；evidence_mapping_*.csv 保存证据回溯字段。

4 多模态预测模型

4.1 标准化与模态投影

设训练集统计量为 μ_m 和 σ_m ，仅对有效位置计算，则标准化为

$$\tilde{x}_{i,t}^{(m)} = \frac{x_{i,t}^{(m)} - \mu_m}{\max(\sigma_m, \varepsilon)}. \quad (3)$$

随后使用模态专属投影映射到统一隐空间：

$$e_{i,t}^{(m)} = \text{LN}(W_m \tilde{x}_{i,t}^{(m)} + b_m), \quad e_{i,t}^{(m)} \in \mathbb{R}^{64}. \quad (4)$$

验证集、测试集和附件四均复用 train_standardizer.npz，不重新估计均值和方差。

4.2 掩码感知时序编码

加入可学习位置表示 p_t 后，对每个模态使用独立 Transformer 编码器：

Q3 technical route and audit boundary




图 1: 问题三技术路线

Data boundary and leakage control




图 2: 数据边界

$$\bar{e}_{i,t}^{(m)} = e_{i,t}^{(m)} + p_t, \quad H_i^{(m)} = \text{Encoder}_m(\bar{E}_i^{(m)}, M_i^{(m)}). \quad (5)$$

无效键位置在注意力中被屏蔽。编码结果采用掩码平均池化：

$$g_i^{(m)} = \frac{\sum_{t=1}^{L_m} m_{i,t}^{(m)} H_{i,t}^{(m)}}{\max(1, \sum_{t=1}^{L_m} m_{i,t}^{(m)})}. \quad (6)$$

该处理保证 padding 不会被当作情感信息，并支持局部模态缺失。

4.3 文本引导的跨模态交互

以文本序列为查询，分别从音频和视觉中提取补充信息：

$$R_i^{T \leftarrow A} = \text{MHA}(H_i^{(T)}, H_i^{(A)}, H_i^{(A)}; M_i^{(A)}), \quad (7)$$

$$R_i^{T \leftarrow V} = \text{MHA}(H_i^{(T)}, H_i^{(V)}, H_i^{(V)}; M_i^{(V)}). \quad (8)$$

源码中两类跨模态响应按照文本有效位置池化后加到文本摘要，再与音频、视觉摘要组成门控输入：

$$\tilde{g}_i^{(T)} = g_i^{(T)} + \text{Pool}(R_i^{T \leftarrow A}) + \text{Pool}(R_i^{T \leftarrow V}), \quad G_i = [\tilde{g}_i^{(T)}; g_i^{(A)}; g_i^{(V)}]^\top. \quad (9)$$

图 3 展示实际模型结构。跨模态注意力用于表征增强，不直接作为最终解释。

4.4 动态门控与双任务输出

对每个样本和模态计算门控分数：

$$a_i^{(m)} = w^\top G_{i,m} + b, \quad \text{quad}\alpha_i^{(m)} = \frac{q_i^{(m)} e^{a_i^{(m)}}}{\sum_r q_i^{(r)} e^{a_i^{(r)}} + \varepsilon}, \quad (10)$$

其中 $q_i^{(m)}$ 表示模态是否存在有效观测。融合表示为

$$z_i = \text{MLP} \left(\sum_{m \in \{T, A, V\}} \alpha_i^{(m)} G_{i,m} \right). \quad (11)$$

分类概率和回归输出分别为

$$p_i = \text{softmax}(W_{cls} z_i + b_{cls}), \quad (12)$$

$$\hat{y}_i = 3 \tanh(w_{reg}^T z_i + b_{reg}). \quad (13)$$

联合目标函数为

$$\mathcal{L} = \lambda_{cls} \mathcal{L}_{CE} + \lambda_{reg} \mathcal{L}_{SmoothL1}, \quad \lambda_{cls} = \lambda_{reg} = 1. \quad (14)$$

5 反事实解释模型

5.1 模态贡献

固定预测模型后，对模态 m 使用训练集均值基线进行替换，得到 $(p_i^{-m}, \hat{y}_i^{-m})$ 。分类和回归变化分别为

$$\Delta_{i,m}^{cls} = D_{KL}(p_i \| p_i^{-m}), \quad \Delta_{i,m}^{reg} = |\hat{y}_i - \hat{y}_i^{-m}|. \quad (15)$$

在验证集预先固定尺度后定义综合敏感性 $r_{i,m}$ ，并归一化为

$$c_{i,m} = \frac{\max(r_{i,m}, 0)}{\sum_{r \in \{T, A, V\}} \max(r_{i,r}, 0) + \varepsilon}. \quad (16)$$

$c_{i,m}$ 之和约为1，最大值对应主要模态。该值是模型后验敏感性，不是因果真值。

5.2 局部证据与忠实性

局部窗口长度和步长均为7。对窗口内特征执行基线替换，计算

$$r_{i,m,k}^{local} = \rho D_{KL}(p_i \| p_i^{-m,k}) + (1 - \rho) |\hat{y}_i - \hat{y}_i^{-m,k}|. \quad (17)$$

每个样本保留 Top-3 窗口。验证集 728 个样本中，高重要性窗口平均影响为 0.0748529，低重要性窗口为 0.0032877，差值为 0.0715652，比例为 22.7675。该结果支持窗口排序具有模型敏感性区分能力。

图 4 是验证集忠实性诊断；它验证的是遮挡排序与模型输出变化的一致性，不是人工证据准确率。

6 实验设置与评价指标

6.1 实验配置

参数	实际设置
特征版本	aligned_50, 长度 50
输入维度	768 / 74 / 35
隐空间、层数、头数	64 / 1 / 4
Dropout	0.1
Batch size、Epoch	64 / 50
学习率、权重衰减	2×10^{-5} / 1×10^{-4}
随机种子、设备	20260924 / CUDA
解释基线	train_mean, 标准化训练特征空间
窗口、步长、Top-K	7 / 7 / 3

训练曲线来自 `training_curve.csv`, 模型在第 29 个 epoch 获得最低验证损失 1.1744457, 最终保留该最佳 epoch 对应权重。

图 5 与训练日志共同表明，训练损失从第 1 个 epoch 的 1.7918299 降至第 50 个 epoch 的 0.8410989；验证损失在第 29 个 epoch 达到 1.1744457，之后未继续改善，模型选择遵循验证集而非测试集。

6.2 评价指标

分类采用 Accuracy 与 Macro-F1，回归采用 MAE 与 Pearson：

$$Accuracy = \frac{1}{N} \sum_i \mathbf{1}(\hat{c}_i = c_i), \quad Macro-F1 = \frac{1}{3} \sum_{c=0}^2 F1_c. \quad (18)$$

Masked multimodal Transformer architecture




图 3: 模型结构




图 4: 验证集解释忠实性

$$MAE = \frac{1}{N} \sum_i |\hat{y}_i - y_i|, \quad (19)$$

$$Pearson = \frac{\sum_i (\hat{y}_i - \bar{\hat{y}})(y_i - \bar{y})}{\sqrt{\sum_i (\hat{y}_i - \bar{\hat{y}})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}. \quad (20)$$

7 有标签实验结果

7.1 总体性能

表 1 直接对应 `model_metrics.csv`。

表 1 双任务模型总体性能

划分	Accuracy	Macro-F1	MAE	Pearson
valid (728)	0.607143	0.547565	0.652097	0.580993
test (727)	0.672627	0.595023	0.679413	0.625911

图 6 和图 7 展示分类混淆结构。test Accuracy 为 0.672627、Macro-F1 为 0.595023；回归 MAE 为 0.679413，Pearson 为 0.625911。当前只使用一个随机种子，因此不报告显著性或多种子置信区间。

7.2 类别级结果

表 2 验证集分类报告

类别	Precision	Recall	F1	Support
Negative	0.6465	0.6214	0.6337	206
Neutral	0.4433	0.2337	0.3060	184
Positive	0.6259	0.8018	0.7030	338

表 2 来自 `classification_report_valid.csv`。Positive 类召回率最高，而 Neutral 类召回率仅为 0.2337，说明中性样本容易被划入相邻极性类别。该现象仅作为当前运行的误差结构，不在缺少重训练对照的条件下归因于某个单一机制。

图 8 和图 9 是实际生成的回归诊断图，用于观察连续强度的预测偏差与离散程度，不能替代表 1 的 MAE 和 Pearson。

8 模态贡献与后验诊断

8.1 全局模态贡献

表 3 反事实模态贡献统计

划分	模态	样本数	平均贡献	标准差	中位数
valid	text	728	0.564601	0.207986	0.583357
valid	audio	728	0.241857	0.153316	0.225415
valid	vision	728	0.193542	0.126525	0.178919
test	text	727	0.571946	0.207630	0.596444
test	audio	727	0.245046	0.152818	0.225407
test	vision	727	0.183009	0.128257	0.167823
attachment4	text	20	0.641696	0.186134	0.716467
attachment4	audio	20	0.197818	0.136718	0.166865
attachment4	vision	20	0.160485	0.115804	0.142188

表 3 来自 `modality_contribution_summary.csv`；附件四三行是 20 个无标签样本的模态贡献统计，原始样本记录在 `predictions_attachment4.csv`。有标签数据中，文本平均贡献约 0.565–0.572，音频约 0.242–0.245，视觉约 0.183–0.194。该结果表示当前模型对文本输入更敏感，不表示文本在真实情感形成中必然最重要。

图 10 和图 11 分别展示全局贡献及验证集贡献分布。三类贡献均来自遮挡后输出变化，而不是直接读取门控值。

8.2 模态移除诊断

表 4 固定模型的后验模态移除结果

划分	移除模态	Accuracy	Macro-F1	MAE	Pearson
valid	none	0.607143	0.547565	0.652097	0.580993
valid	text	0.287088	0.263764	0.869413	-0.020699
valid	audio	0.604396	0.571687	0.716655	0.579688
valid	vision	0.629121	0.576199	0.694256	0.573931
test	none	0.672627	0.595023	0.679413	0.625911
test	text	0.288858	0.266980	0.989222	-0.064822
test	audio	0.678129	0.625366	0.733368	0.638242

划分	移除模态	Accuracy	Macro-F1	MAE	Pearson
test	vision	0.672627	0.592638	0.725985	0.613138

表 4 直接来自 `modality_ablation_metrics.csv`，是固定模型的后验模态移除诊断，不是重新训练的单模态基线。移除文本后 valid Accuracy 降至 0.287088、test Accuracy 降至 0.288858，且 Pearson 分别降至 -0.020699 和 -0.064822，说明模型预测对文本输入高度敏感；音频、视觉移除后的分类变化较小，但回归误差上升，说明二者仍可能提供补充强度信息。

图 12 展示门控值与反事实贡献的关系。`gate_contribution_consistency.csv` 给出的 Pearson 相关系数为 text 0.1050、audio 0.0349、vision 0.0061，相关性较弱，进一步说明门控值不能替代反事实贡献。图 13 展示映射质量统计，所有附件四证据行均完成边界检查，未发生证据行被截断。

9 局部证据、关键帧与附件四结果

9.1 局部重要性

`local_importance_valid.csv`、`local_importance_test.csv` 和 `local_importance_attachment4.csv` 分别保存三种划分的窗口影响；图 14–16 展示相应热力图。valid 和 test 热力图可结合真实标签分析证据与误差，附件四热力图只用于推理证据展示。

图 14–16 的横轴是对齐窗口位置，纵轴是样本，颜色表示反事实遮挡影响。它们提供的是可回溯的模型证据排序，不应被表述为逐词情感原因。

9.2 代表性样本

表 5 代表性验证样本

类型	sample_id	真实/预测类别	真实/预测强度	主要模态	文本/音频/视觉贡献
文本主导	jICmfLeFymA\$\$_\$16	2 / 2	1.667 / 1.029	text	0.976 / 0.005 / 0.018
音频主导	PboaYD5hlG8\$\$_\$8	0 / 2	-1.333 / 0.338	audio	0.167 / 0.735 / 0.098
视觉主导	wosolsrH3seM\$\$_\$6	2 / 0	0.333 / -0.763	vision	0.092 / 0.159 / 0.749
分类错误	OutROiKxejc\$\$_\$1	1 / 2	0 / -0.016	text	0.582 / 0.206 / 0.212
回归误差最大	252998\$\$_\$7	2 / 0	1.333 / -1.996	text	0.603 / 0.061 / 0.337
贡献均衡	TYJzg5IJN8o\$\$_\$11	0 / 2	-0.333 / 0.380	audio	0.335 / 0.345 / 0.320

表 5 来自 `representative_sample_selection.csv`。其中音频主导和视觉主导样本均

出现分类错误，说明主要模态是模型的依赖来源而不是正确性保证；该表因此同时承担解释案例和失败案例的作用。

9.3 附件四最终推理

附件四预测结果保存在 `predictions_attachment4.csv`，20 条样本均生成类别、强度、门控、模态贡献、Top-3 证据影响和解释配置。代表性输出如下：样本 01 预测 Positive、强度 0.6411、主要模态 text；样本 02 预测 Negative、强度 -0.0867、主要模态 audio；样本 18 预测 Positive、强度 -1.0973、主要模态 vision；样本 16 预测 Negative、强度 -2.6106、主要模态 text。类别和连续强度是两个输出，不能仅根据类别推断强度符号。

表 6 附件四代表性证据

样本	预测类别	强度	主要模态	Top-1 证据区间（秒）	影响
01	Positive	0.6411	text	2.520–3.780	0.0478
02	Negative	-0.0867	audio	0.471–0.943	0.0974
09	Negative	-1.9809	text	4.228–4.933	0.1281
16	Negative	-2.6106	text	2.604–3.038	0.0362
18	Positive	-1.0973	vision	13.090–15.708	0.1737

表 6 取自 `table_evidence_examples.csv`；完整 20 条记录和证据文本在 `evidence_mapping_attachment4.csv` 中。每个样本均有一张解释卡和三个以内的模态关键帧，`keyframes.json` 与 `evidence_cards.json` 用文件名记录了元数据对应关系。

图 17 是视频解码审计。20 个视频均能完成解码，但 16 个视频的容器声明帧数与实际解码帧数不一致；因此证据边界以实际解码帧数为准，并在审计文件中保留该异常。

10 论文支撑材料与可复现性

当前结果包中的图、表、数据和审计材料形成如下对应关系：

论文内容	实际支撑文件
技术路线、模型结构、数据边界	<code>fig_technical_route.png</code> 、 <code>fig_model_architecture.png</code> 、 <code>fig_data_boundary.png</code>
训练过程	<code>training_curve.csv</code> 、 <code>fig_training_curve.png</code>

论文内容	实际支撑文件
分类与回归性能	model_metrics.csv、 classification_report_valid.csv、混淆矩阵和回归诊断图
模态贡献与移除诊断	modality_contribution_summary.csv、 modality_ablation_metrics.csv、 fig_global_contribution.png
解释忠实性	explanation_parameter_selection.json、 fidelity_metrics.json、 fig_fidelity_valid.png
局部证据	local_importance_*.csv、 evidence_mapping_*.csv、局部重要性热力图
附件四案例	predictions_attachment4.csv、 table_evidence_examples.csv、 keyframes/、evidence_cards/
数据质量与边界	validation_audit.json、 video_decode_audit.csv、v8_audit.json、 final_package_audit.json

结果审计显示：输出均为有限值，train/valid/test 主键互不交叉，附件四完整生成 20 条预测，证据贡献可归一化，关键帧和解释卡与 JSON 元数据一一对应，附件四未参与训练或解释参数选择。模型权重、标准化参数、运行配置、训练日志和校验摘要共同构成复现材料。

11 结果边界与局限性

第一，当前没有不同网络结构的重新训练基线，表 4 不能替代完整消融实验。第二，主要结果来自单一随机种子，未报告多种子均值、标准差和置信区间。第三，文本定位是对齐相对窗口，不是逐词时间戳。第四，附件四视频存在容器帧数和实际解码帧数不一致，关键帧解释必须结合视频审计。第五，门控值、注意力权重和 impact_score 都是模型内部状态或后验敏感性，不是人工标注的真实情感原因。第六，附件四无标签，任何性能评价只能停留在附件二 valid/test。

上述限制不否定当前输出对论文撰写的作用，但要求论文对“模型表现”“模型依赖”“证据映射”和“真实情感原因”进行严格区分。所有指标、图表和案例均应以结果包中的文件为准，不补写未运行的实验结论。




图 5: 训练曲线




图 6: 验证集混淆矩阵




图 7: 测试集混淆矩阵




图 8: 验证集回归诊断




图 9: 测试集回归诊断




图 10: 全局贡献




图 11: 验证集模态贡献




图 12: 门控与反事实贡献




图 13: 门控一致性




图 14: valid 局部重要性




图 15: test 局部重要性




图 16: 附件四局部重要性




图 17: 附件四视频解码审计